

Análisis de Discursos Políticos de la Campaña Presidencial de Estados Unidos 2020

Tarea 1, Introducción a la Ciencia de Datos, FING 2025

Ignacio Campón y Mauro Loprete

En el presente trabajo se analizan distintos discursos políticos correspondientes a la campaña presidencial de Estados Unidos en el año 2020.

La base de datos empleada contiene un total de 269 observaciones y 6 variables, que incluyen discursos de campaña, presentaciones en ayuntamientos, entrevistas, debates y otros eventos. Los discursos se encuentran clasificados según orador, título, contenido, fecha, localidad y tipo de discurso. El análisis se centra particularmente en los discursos de campaña política, poniendo énfasis en los cinco oradores con mayor frecuencia de participación.

Para identificar esta categoría de discursos, se realiza en primer lugar un análisis de los datos faltantes presentes en la base. Las variables disponibles se agrupan en tres tipos principales:

- **Categóricas:** *speaker* (nombre del orador), *type* (tipo de discurso) y *location* (ciudad y estado donde se realizó el discurso).
- **Texto:** *title* (título del discurso) y *text* (contenido del discurso).
- **Fecha:** *date* (fecha del discurso en formato año/mes/día).

La cantidad de datos faltantes por variable se detalla en la Figura 1.

Cantidad de Datos Faltantes		
Variable	Cantidad de Nulos	Porcentaje
speaker	3	1.1 %
title	0	0.0 %
text	0	0.0 %
date	0	0.0 %
location	18	6.7 %
type	21	7.8 %

Figura 1: Distribución de Datos Faltantes por Variable

Se identifican datos faltantes únicamente en las variables *speaker*, *location* y *type*. En particular, la variable *speaker* presenta 3 observaciones incompletas, *location* cuenta con 18 datos faltantes, y *type* registra 21 valores ausentes. Luego de aplicar un filtrado para conservar únicamente los discursos de campaña, los datos faltantes remanentes corresponden a 1 observación en *speaker* y 4 en *location*. Esta situación no genera consecuencias relevantes, dado que no se pierde información significativa. En cuanto a la variable *type*, el filtrado por discursos de campaña elimina completamente los datos faltantes.

Para verificar la calidad de los datos, se realiza una inspección manual con el objetivo de detectar posibles registros incompletos, inconsistentes o con ruido, probablemente atribuibles a errores en la producción y/o procesamiento de la información. Como resultado, no se identifican problemas significativos, por lo que se considera que la calidad de los datos es adecuada.

La cantidad de observaciones según el tipo de discurso se resume en la Figura 2. Se observa que 180 de las 269 observaciones, lo que representa un 72,6 %, corresponden a discursos de campaña. Estas observaciones constituyen la base principal del análisis.

Participación en Debates Presidenciales		
Cantidad y porcentaje de intervenciones por tipo		
Tipo de intervención	Cantidad	Porcentaje
Campaign Speech	180	72.6 %
Town Hall	18	7.3 %
Interview	14	5.6 %
Debate	9	3.6 %
Endorsement	8	3.2 %
Statement	8	3.2 %
Roundtable	8	3.2 %
Press Conference	2	0.8 %
Voter Mobilization	1	0.4 %
Total	248	100.0 %

Figura 2: Cantidad de Discursos por Tipo

Los discursos de campaña abarcan un período comprendido entre el 15 de enero de 2020 y el 16 de octubre de 2020. La mediana de las fechas se sitúa a finales de agosto, lo que sugiere una mayor concentración de discursos en los últimos meses del período analizado. En la Figura 3 se pueden observar la frecuencia de discursos por candidato de los cinco oradores más activos.

Los cinco candidatos con mayor cantidad de discursos de campaña concentran el 65 % del total de discursos registrados. Estos oradores son Kamala Harris, Bernie Sanders, Mike Pence, Donald Trump y Joe Biden. El 35 % restante corresponde a 53 oradores con menor frecuencia de aparición. A partir de este punto, el análisis se basará exclusivamente en los discursos pronunciados por estos cinco candidatos.




Figura 3: Cantidad de discursos entre los 5 candidatos con mayor frecuencia

Al observar la distribución temporal de los discursos, es posible identificar momentos clave dentro del desarrollo de la campaña. Para ello, se construye la Figura 4, que consiste en un gráfico de líneas y puntos representados sobre un eje temporal.




Figura 4: Cantidad de discursos por candidato a lo largo del tiempo

Tal como se observa en la figura anterior, la campaña de los candidatos comienza en enero de 2020 con una frecuencia baja, registrándose no más de cinco discursos por mes. En abril, la cantidad de discursos de Bernie Sanders desciende a cero, lo que coincide con el anuncio de su retiro de la campaña y su respaldo a Joe Biden por parte del Partido Demócrata de Estados Unidos. Esto explica que se registre un único discurso de este candidato en los últimos tres meses del período analizado.

Por otra parte, en julio se identifica el inicio de la campaña de Kamala Harris y, posteriormente, en agosto, el anuncio de su integración a la fórmula presidencial junto a Joe Biden. En septiembre se alcanza el pico en la cantidad de discursos pronunciados por los dos principales candidatos a la presidencia de Estados Unidos, en el contexto del debate presidencial televisado a nivel nacional y la proximidad de las elecciones en el mes siguiente.

La Figura 5 presenta la cantidad mensual de discursos por fórmula presidencial. En este gráfico se agregan los discursos de Joe Biden & Kamala Harris, por un lado, y de Donald Trump & Mike Pence, por otro. Se observa un incremento en la frecuencia de discursos por fórmula a partir del mes de julio.

Para normalizar el texto, se realizaron modificaciones menores a la función `clean_text()`. Se




Figura 5: Cantidad de discursos por fórmula presidencial a lo largo del tiempo

incorporaron los nombres de los candidatos, ya que se detectó que en los discursos el nombre y apellido del orador suelen aparecer seguidos de dos puntos (por ejemplo, “Donald Trump:”), lo cual generaba repeticiones innecesarias en el contenido textual de un mismo candidato. Por este motivo, luego de convertir todo el texto a minúsculas, se eliminan las siguientes frases: joe biden:, donald trump:, kamala harris:, mike pence:, bernie sanders:, president trump:. La inclusión de los dos puntos junto al nombre y apellido garantiza que no se eliminen menciones realizadas por un orador hacia otro candidato.

Adicionalmente, se incorporó una sentencia para eliminar signos de puntuación específicos, reemplazándolos por espacios. En particular, se eliminaron los caracteres: [], „, :, ?, ., !, ;, “, ’, así como también los saltos de línea (\n), utilizando una expresión regular. Este proceso permite limpiar el texto de manera adecuada antes de aplicar técnicas de análisis textual.

Durante sus discursos, los candidatos utilizan un vocabulario similar, y ciertas palabras presentan una frecuencia más alta entre ellos. En la Figura 6 se presentan las palabras más frecuentes mencionadas en los discursos de los candidatos.

Se observa que las 20 palabras más frecuentes en los discursos de todos los candidatos son mencionadas con mayor frecuencia por el orador Donald Trump. Esto podría sugerir que los discursos de este candidato son más homogéneos en comparación con los de los demás oradores. Al agrupar las palabras más frecuentes por fórmula presidencial, se identifica un patrón similar (véase la figura Figura 7), lo que permite distinguir diferencias entre los discursos




Figura 6: Frecuencia de las 20 palabras más usadas por los 5 candidatos con mayor cantidad de discursos

de los candidatos de los distintos partidos políticos. Si se analizaran las diferencias en los lugares y fechas de los discursos, sería posible generar listas con las localidades más visitadas por los candidatos, así como los meses en los que se registró la mayor cantidad de discursos.




Figura 7: Frecuencia de las 20 palabras más usadas por fórmula presidencial

Existen numerosas palabras que son utilizadas exclusivamente por cada fórmula presidencial. Por ejemplo, Donald Trump y Mike Pence emplean vocabulario como “great”, “years”, “don’t”, “right”, “want”, que no son utilizados por Joe Biden y Kamala Harris. Esto podría indicar que los discursos de los candidatos son distintos entre sí, reflejando diferencias en sus posturas políticas. Por otro lado, Joe Biden y Kamala Harris utilizan palabras como “thank”, “i’m”, “get”, “make”, “back”, “country”, las cuales no son empleadas por la fórmula Trump-Pence. Se observa un tipo de discurso más individualista en el uso de la palabra “i’m” por parte de Joe y Kamala, mientras que la fórmula Trump-Pence utiliza un vocabulario más colectivo con la expresión “we’re”.

Al analizar las palabras más frecuentes por candidato, se identificó un problema particular: los propios candidatos se mencionan a sí mismos con gran frecuencia, un patrón que se repetía en los cinco oradores. Para resolver esta situación, se decidió filtrar las frases de los discursos que mencionan al orador, lo que eliminó la aparición frecuente de los nombres de los propios candidatos.




Figura 8: Matriz de menciones entre candidatos.

La Figura 8 presenta una matriz de menciones entre los candidatos. Las filas representan a los candidatos y las columnas indican las menciones dirigidas hacia ellos. Para construir esta matriz, se elaboró una lista con los nombres de los candidatos y se contabilizaron las menciones de cada uno en los discursos de los demás. Por ejemplo, en los discursos de Donald Trump se buscaron menciones a Joe, a Biden y al nombre completo, siendo estas categorías excluyentes entre sí.

La diagonal principal de la matriz refleja la cantidad de veces que un candidato se menciona a sí mismo, mientras que el resto de la matriz muestra las menciones hacia otros candidatos. Se observa que Donald Trump y Joe Biden son los que más se mencionan mutuamente, lo cual es lógico dado que fueron los principales opositores. Donald Trump es el candidato que más menciona a los demás integrantes del top 5 de oradores. Por otro lado, Bernie Sanders es el único candidato que no menciona a los demás dentro del top 5, en particular a Mike Pence, y es también quien realiza menos menciones en general.




Figura 9: Grafo de menciones entre candidatos.

El grafo presentado en la Figura 9 representa las menciones entre distintos candidatos políticos, donde cada nodo corresponde a un candidato y las flechas indican quién menciona a quién. Se observa una red densa de interacciones, con varios candidatos que se mencionan mutuamente y también a sí mismos. Figuras como Joe Biden, Kamala Harris y Bernie Sanders reciben numerosas menciones, lo que sugiere un rol central en el discurso político, mientras que Donald Trump y Mike Pence destacan por ser quienes más mencionan a otros, posiblemente como parte de una estrategia discursiva activa. Las relaciones bidireccionales indican enfrentamientos o colaboraciones visibles, y la presencia generalizada de autorreferencias muestra que todos los candidatos tienden a hablar de sí mismos, algo típico en contextos políticos. En conjunto, el grafo permite visualizar dinámicas de visibilidad, centralidad e interacción entre los candidatos.

Una vez finalizada la limpieza de los textos —eliminando menciones repetidas, signos de puntuación innecesarios y normalizando el contenido—, estamos en condiciones de avanzar hacia un análisis más profundo. En particular, resulta pertinente estudiar los sentimientos expresados en los discursos, lo que nos permitirá explorar el tono emocional de cada intervención y observar cómo varía a lo largo de la campaña. Asimismo, es relevante analizar si existe coincidencia en las localidades donde los candidatos presentan sus discursos, tanto entre ellos como entre los distintos partidos políticos. A partir de esto, nos planteamos tres preguntas clave para guiar el análisis.

En primer lugar, surge la pregunta de **¿cómo varía el tono emocional de los discursos de los candidatos a lo largo del tiempo?** A través del análisis de sentimientos, podemos evaluar el tono de los discursos (positivo, negativo, neutral) y observar cómo este cambia en momentos clave de la campaña, como durante los debates o los anuncios importantes. Es posible crear listas de palabras que consideremos positivas, negativas y neutrales, y buscar que postura toma cada candidato.

Una segunda cuestión interesante es **¿cómo se perciben emocionalmente las menciones entre los candidatos?** Este análisis puede revelar si, en sus discursos, los candidatos emplean un tono más agresivo o elogioso al mencionar a sus oponentes, especialmente durante momentos de confrontación directa o alianzas. Podemos buscar las menciones de los oradores hacia otros candidatos, y analizar el tono de estas menciones.

Por otro lado, puede ser pertinente preguntarnos **¿existen diferencias en las localidades de los candidatos donde realizan sus discursos?** Un análisis de las localidades que cada candidato visita puede ofrecer información sobre su estrategia de campaña y su enfoque en diferentes regiones del país. Puede realizarse fácilmente analizando la variable *location* de los discursos, y comparando la cantidad de discursos por localidad y candidato.

En conclusión, el análisis de sentimientos y menciones entre candidatos, así como la exploración de las localidades de los discursos, puede proporcionar una visión más profunda de la dinámica de la campaña electoral y las estrategias comunicativas de los candidatos. Estos enfoques permiten no solo entender el contenido de los discursos, sino también su impacto emocional y su contexto geográfico.